

SESIÓN 4 · MIÉRCOLES 28 DE OCTUBRE

IA GENERATIVA PARA EL ANÁLISIS DE DATOS

Un flujo iterativo con el humano en el circuito: usted decide qué se analiza y por qué; el modelo ejecuta y usted valida cada paso.

PANORAMA DE LA SESIÓN

01 Los datos

Qué es estructurado, qué no, y qué queda en el medio. Con un ejemplo de cada uno.

03 El circuito

Cinco etapas, tres roles, y el único punto donde parar sale barato.

02 Código y modelos

Dónde se acaban Excel y SQL, por qué el código, y qué cambia cuando lo escribe un modelo.

04 Demostración

Datos reales de 6 497 vinos y tres prompts encadenados que usted se lleva.



BLOQUE 01

LOS DATOS

Antes de pedirle nada a un modelo, hay que saber qué se le está dando.



FILAS Y COLUMNAS, CON UN TIPO POR COLUMNA

La misma información puede vivir en tres lugares. En los tres, cada fila es un registro y cada columna tiene un significado fijo.

Base de datos SQL

Tablas relacionadas entre sí. Se consulta con un lenguaje propio.

```
SELECT lote, rendimiento  
FROM ensayos  
WHERE temperatura > 60;
```

Hoja de cálculo

La misma tabla, con celdas que se editan a mano y fórmulas encima.

A	B	C
lote	temperatura	rendimiento
26-A	65	0.82
26-B	58	0.71

Archivo CSV

Texto plano: una fila por línea, columnas separadas por comas. Lo lee cualquier programa.

```
lote,temperatura,rendimiento  
26-A,65,0.82  
26-B,58,0.71
```



TRES GRADOS DE ESTRUCTURA

Estructurado

Formato predefinido. Se filtra, se ordena y se suma sin interpretar nada.

Tablas, hojas de cálculo, CSV.

lote	temp	rend.
26-A	65	0.82
26-B	58	0.71

Semiestructurado

Trae etiquetas que dicen qué es cada cosa, pero admite anidamiento y campos distintos por registro. No cabe en una tabla sin aplanarlo.

JSON, YAML, XML. Así responde una API y así devuelve datos un modelo.

```
{ "lote": "26-A",  
  "temp": 65,  
  "notas": ["espuma", "olor"] }
```

No estructurado

Sin formato. Hay que procesarlo antes de poder preguntarle algo.

Texto libre, imágenes, audio, video.

```
bitácora, 14 de mayo  
El lote 26-B salió con espuma  
y un olor raro a las 3 h. Bajé  
la temperatura y mejoró.
```



LOS DATOS ESTRUCTURADOS SOSTIENEN LA OPERACIÓN

Trazabilidad

Qué lote salió, cuándo, con qué materia prima y con cuántos rechazos.

lote	fecha	kg	rechazos
26-A	05-14	480	4
26-B	05-15	462	11

Finanzas

Presupuesto contra gasto real, mes a mes.

rubro	pres.	real
reactivos	2.4M	2.9M
equipos	1.1M	0.8M

Clientes

Quién compra, qué pide y cada cuánto vuelve.

cliente	pedidos	ultimo
Andina	14	05-02
Norte	3	03-19

Investigación

Mediciones repetidas bajo condiciones controladas.

ensayo	T	pH	rend.
1	60	6.5	0.79
2	65	6.5	0.82



CUATRO COSAS QUE EL ANÁLISIS A MANO NO AGUANTA

LÍMITE	QUÉ PASA	EN EL LABORATORIO
Tiempo	Crece con el volumen	Tres tardes cruzando dos hojas a mano
Error	Copiar y pegar falla callado	Una columna corrida una fila; nadie lo nota hasta el informe
Escala	Lo que sirve para cien filas no sirve para cien mil	El sensor escribe una lectura por segundo
Alcance	Lo sutil no se ve mirando	El rendimiento cae solo con pH bajo y proveedor B a la vez

EL PROBLEMA DE FONDO El rendimiento está en la tabla y la explicación en la bitácora. Ninguna herramienta tradicional cruza eso sola.



EL ANÁLISIS SERIO PEDÍA CUATRO OFICIOS

Cada uno toma meses. Por eso el análisis quedaba en manos de un especialista y no de quien tenía la pregunta.

Estadística

Saber qué prueba responde qué pregunta, y qué supuestos exige.

```
# ¿difieren A y B?  
t de Student,  
Mann-Whitney,  
ANOVA de un factor...
```

SQL

Sacar de la base exactamente las filas que hacen falta.

```
SELECT AVG(rend.)  
FROM ensayos  
GROUP BY lote;
```

Programación

Automatizar lo que se repite. Python o R.

```
df = pd.read_csv("e.csv")  
df.groupby("lote")  
    ["rend"].mean()
```

Visualización

Elegir el gráfico que muestra la relación sin distorsionarla.

```
# dispersión, no barras  
plt.scatter(df.pH,  
            df.rend)
```

BLOQUE 02

CÓDIGO Y MODELOS

El código sigue siendo el que hace el trabajo. Lo que cambió es quién lo escribe.



DÓNDE SE ACABAN EXCEL Y SQL

HERRAMIENTA	HASTA DÓNDE LLEGA	DÓNDE SE ACABA
Excel	Hasta 1.048.576 filas por hoja, con fórmulas y gráficos a mano	Pasado ese tope el archivo no abre completo: no es que vaya lento, es que no cabe. Y cruzar dos hojas es frágil.
SQL	Millones de filas, consultas exactas y repetibles	Hay que saber escribirlo. Unir fuentes distintas —la base, el CSV del sensor, la bitácora— se vuelve engorroso.

DATO VERIFICABLE El tope de Excel es 2^{20} filas por hoja desde la versión 2007. Un archivo de sensor a una lectura por segundo lo llena en doce días.



TRES COSAS QUE SOLO EL CÓDIGO HACE BIEN

01 Se repite

Lo mismo, igual, todas las veces.
El análisis del lote 27 es el del 26
con otro archivo.

```
for lote in lotes:  
    analizar(lote)
```

02 Se escala

Cien filas o diez millones: el
mismo guion, el mismo tiempo
de escribirlo.

```
df = pd.read_csv("sensor.csv")  
# 1 fila o 10 000 000  
df.rend.describe()
```

03 Se audita

Queda escrito qué se hizo y en qué
orden. Otro puede repetirlo y
encontrar el error.

```
# paso 3: quitar T > 90  
df = df[df.temp <= 90]  
# 17 filas eliminadas
```



LO QUE CUESTA Y LO QUE CAMBIA

PROGRAMAR CUESTA UN SEMESTRE. EL MODELO BAJA ESE COSTO, NO EL DE PENSAR

Cuatro costos que no desaparecen porque usted tenga una buena pregunta.

Sintaxis. Dónde va cada paréntesis.

Lógica. Pensar el problema como pasos.

Depuración. Encontrar por qué no corre.

Mantenimiento. Que siga corriendo el semestre entrante.

El modelo absorbe los cuatro. Lo que no absorbe es decidir qué vale la pena analizar.

LO QUE USTED ESCRIBE

```
Compara el rendimiento promedio por lote  
y dime si la diferencia es significativa.
```

LO QUE EL MODELO DEVUELVE

```
medias = df.groupby("lote")["rend"].mean()  
a, b = df[df.lote=="26-A"].rend, df[df.lote=="26-B"].rend  
t, p = stats.ttest_ind(a, b)  
print(medias, f"p = {p:.3f}")
```



DATOS COMO TEXTO

EL MODELO NO ABRE SU ARCHIVO: LEE LO QUE USTED LE PEGA

Por eso importa el formato en que se lo pega.

Los tres formatos que siguen codifican exactamente esta tabla. Misma información, tres maneras de escribirla; cada una con un uso.

MARCA	COSTO	DESCRIPCIÓN
Toyota Corolla	22 000	Sedán compacto, bajo consumo
Tesla Model 3	42 000	Sedán eléctrico, autonomía larga
BMW X5	65 000	Todoterreno de lujo, motor potente

CSV, JSON Y YAML LADO A LADO

CSV

El más compacto. Una línea por registro. Las comas dentro del texto van entre comillas o rompen las columnas.

Para pegar una tabla en un chat, o exportar de Excel.

```
marca, costo, descripcion
Toyota Corolla, 22000, "Sedan compacto, bajo consumo"
Tesla Model 3, 42000, "Sedan electrico, autonomia larga"
```

JSON

Cada registro nombra sus campos. Más largo, pero nunca se desalinea y admite anidar.

Lo que devuelve una API y lo que devuelve el modelo si le pide estructura.

```
[ { "marca": "Toyota Corolla",
  "costo": 22000 },
  { "marca": "Tesla Model 3",
    "costo": 42000 } ]
```

YAML

Lo mismo que JSON, sin llaves ni comillas obligatorias. La sangría es la sintaxis.

Archivos de configuración. Un espacio de más y deja de ser válido.

```
carros:
  - marca: Toyota Corolla
    costo: 22000
  - marca: Tesla Model 3
    costo: 42000
```



BLOQUE 03

EL CIRCUITO

Cinco etapas. En tres decide usted; en dos, el modelo ejecuta.



DE LA IDEA AL PLAN

NO EMPIECE PIDIENDO CÓDIGO

ASÍ NO

Hazme un análisis de este CSV.

Obtiene código que corre y no responde nada.
El modelo elige la pregunta por usted, y elige la más genérica.

ASÍ SÍ

Tengo rendimiento por lote y por proveedor.
Sospecho que el proveedor B baja el rendimiento solo con pH bajo. ¿Qué análisis lo confirmaría o descartaría? Aún no escribas código.

Le da la sospecha y le pide el plan. El código viene después, cuando usted ya validó qué se va a calcular.



LAS CINCO ETAPAS Y QUIÉN HACE CADA UNA



En naranja, el modelo. Trabajo mecánico sobre el archivo: describir, calcular, ejecutar. Rápido y sin criterio.

En negro, usted. Decidir qué importa, validar el plan, sacar la conclusión. Lento y con contexto que el modelo no tiene.

DIAGNÓSTICO E IDEACIÓN

01 Diagnóstico · la IA

Dimensiones, tipos de variable, faltantes y problemas de calidad. Lo que devuelve es un estado del archivo, no una conclusión.

```
ensayos.csv · 6 columnas  
rend: numérica, hay faltantes  
proveedor: 3 valores únicos  
△ "B" y "b" aparecen como  
proveedores distintos
```

02 Ideación · usted

Lee ese diagnóstico y decide qué importa en su contexto. El modelo no sabe qué pregunta tiene usted.

```
Hipótesis que salen del diagnóstico:  
1. El proveedor B baja el  
rendimiento solo con pH bajo.  
2. Los faltantes no son al azar:  
son los lotes que fallaron.
```



ALINEACIÓN, NAVEGACIÓN Y EVOLUCIÓN

03 Alineación · usted

El punto de control. ¿El plan responde la pregunta que importa? Si no, se vuelve a la 02.

Plan propuesto: 5 análisis.
Descarto el 4 (no aporta).
Agrego: unir "B" y "b"
antes del análisis 1.

04 Navegación · la IA

Ejecución paso a paso. Un análisis por vez, validando el resultado antes de seguir.

Análisis 1 → B rinde menos solo con pH bajo
¿tiene sentido? sí → sigue
Análisis 2 → ...

05 Evolución · usted

Lo que se aprendió cambia la siguiente pregunta. Es la vuelta del circuito.

Aprendido: el efecto existe y depende del pH.
Nueva pregunta: ¿desde qué pH aparece?

ETAPA 03 · EL ÚNICO FRENO BARATO

Antes de ejecutar, corregir el plan cuesta un minuto. Después, cuesta todo el trabajo hecho.

ROLES Y PRINCIPIOS

QUIÉN HACE QUÉ, Y LAS REGLAS QUE LO SOSTIENEN

ROL	HACE	EL PRINCIPIO DETRÁS
La IA ejecuta	Procesa volumen, escribe código, propone hipótesis, deja registro	Acelera la ejecución; no reemplaza la decisión
Usted dirige	Fija el objetivo, aporta contexto, valida y decide	El contexto es suyo: el modelo no sabe por qué un dato está sesgado
La iteración corrige	Nadie acierta de primeras; el valor está en la vuelta	Corrija temprano; suba de simple a complejo solo si verificó el paso anterior

El hilo guarda qué se pidió y por qué. No es documentación todavía —hay que depurarlo— pero ya no se reconstruye de memoria.



ANTES Y DESPUÉS

QUÉ CAMBIA EN LA PRÁCTICA

	TRABAJANDO SOLO	CON EL MODELO EN EL CIRCUITO
El código	Se escribe desde cero, línea por línea	Se genera; usted lo lee y lo valida
La corrección	Al final, cuando ya dolió	En cada paso, antes del siguiente
El registro	Se redacta después, si alcanza el tiempo	Queda el hilo; se depura, no se reconstruye
El cuello de botella	Escribir el análisis	Decidir cuál análisis vale la pena

SIN CIFRAS A PROPÓSITO La versión anterior decía «semanas → horas». Nadie lo midió. Cuando un equipo del curso lo mida, la cifra vuelve.



SI SU PROYECTO LLEGA HASTA ACÁ

UN FLUJO DE AGRUPAMIENTO, CON UN CUIDADO

ETAPA	QUÉ SE HACE	CON QUÉ
Preparar	Cargar, revisar tipos y faltantes, limpiar, normalizar	pandas · StandardScaler
Explorar	Distribuciones, correlaciones, selección de variables	histogramas · matriz de correlación
Agrupar	Elegir método y número de grupos	k-medias, jerárquico, DBSCAN · codo, silueta
Evaluar	Calidad de los grupos y contraste con el dominio	silueta · Davies-Bouldin · ¿tienen sentido?

T-SNE Y UMAP NO VAN ANTES DE AGRUPAR Sirven para ver los grupos: deforman las distancias. Si reduce dimensiones antes de agrupar, use PCA. Con t-SNE o UMAP los grupos que encuentre pueden ser un artefacto de la proyección.



BLOQUE 04

DEMOSTRACIÓN

Un conjunto de datos real y tres prompts encadenados. Escanee y sígalo.



6 497 VINOS, TRECE COLUMNAS

Vino verde portugués, tinto y blanco. Once análisis fisicoquímicos por muestra y una calificación sensorial de catadores, de 0 a 10. Descárguelo antes de empezar.

tipo	acidez volátil	azúcar	pH	alcohol	calidad
tinto	0,70	1,9	3,51	9,4	5
tinto	0,88	2,6	3,20	9,8	5
tinto	0,76	2,3	3,26	9,8	5
tinto	0,28	1,9	3,16	9,8	6



Primeras cuatro filas, seis de las trece columnas. Las unidades están en el diccionario, que se baja con los datos.



DIAGNÓSTICO: EL ESTADO DEL ARCHIVO

Actúa como un analista de datos senior especializado en diagnóstico inicial de datos de laboratorio.

Te comparto un CSV con análisis fisicoquímicos de vinos y una calificación sensorial. Necesito:

1. Dimensiones del archivo
2. Columnas: tipo, contenido y unidad, únicos, faltantes
3. Estadísticas clave de las numéricas
4. Distribución de categorías y de la calificación
5. Problemas de calidad: duplicados, valores imposibles o extremos, clases desbalanceadas
6. Cambios de tipo que faciliten el análisis

Calcula todo con código sobre el archivo completo.

No saques conclusiones sobre qué determina la calidad.



TEXTO COMPLETO

Seis puntos y ninguno interpretativo. Le pide qué hay y que lo calcule, no que lo estime. Interpretar lo hace usted.

LEYÓ EL ARCHIVO COMPLETO Y ENCONTRÓ LOS PROBLEMAS

6 497 filas × 13 columnas · 0 faltantes

1 177 filas duplicadas (18,1 %)

sin ID: ¿error o réplica? no se sabe

76,6 % de las calificaciones en 5 o 6

ácido cítrico = 0 en 151 filas

40 valores de alcohol con 14 decimales

«parecen promedios de réplicas»

Lo verificamos

Cada cifra coincide con un cálculo propio en pandas.

Lo que no sabía

«El archivo no trae diccionario de datos»: las unidades las dedujo. Déselas.

SU TURNO · ETAPA 02 ¿Qué hace con los duplicados? El modelo no lo puede decidir: no sabe cómo se tomaron las muestras. Usted sí, o lo pregunta.



PARE ACÁ · ETAPA 02

¿QUÉ QUIERE OBSERVAR? ¿QUÉ ANÁLISIS LE FALTA A LO QUE LE SUGIRIÓ?

Si salta esta pregunta y ejecuta lo primero que le proponga el modelo, el análisis es del modelo, no suyo.



PLAN: ORDENADO POR PRIORIDAD

Actúa como el líder de un equipo de análisis de datos en una empresa de alimentos y bebidas. Piensa en el valor técnico para el producto y en la viabilidad.

Con base en este análisis exploratorio y en mi pregunta:

1. Cinco análisis descriptivos prioritarios, con justificación y tres gráficos recomendados
2. Dos cruces relevantes entre variables
3. Qué preguntas pueden y no pueden responder los datos
4. Análisis estadísticos según el tipo de variable

Organiza por prioridad e indica la preparación de datos.

Mi pregunta: [LO QUE USTED QUIERE SABER]

La última línea es suya. Sin ella, el modelo elige la pregunta por usted, y elige la más genérica.



TEXTO COMPLETO

ANTES DE PLANEAR, MIDÍO SI SE PODÍA

Pregunta: ¿qué distingue a los vinos de calidad 7 o más? ¿Es igual en tintos y blancos? Sin duplicados.

5 320 vinos · calidad alta: 825 blancos, 184 tintos
→ alcanza para comparar dos grupos
densidad ~ azúcar y alcohol (ρ 0,74 y -0,81)
→ no van juntas en un modelo
→ todo se analiza dentro de cada tipo

Etapa 03 · lo que decidimos

De nueve pasos, uno: comparar las once variables entre alta y no alta, por tipo.

Lo que no se puede

«Son datos observacionales: no se puede afirmar que subir el alcohol “mejore” el vino.»

POR QUÉ UNO SOLO Un análisis por vez se revisa en diez minutos. Nueve juntos se aceptan sin leer.



EJECUCIÓN: UN ANÁLISIS POR VEZ

Actúa como un ingeniero de desarrollo de producto que presenta hallazgos a un comité técnico.

Ejecuta este análisis del plan, sobre el archivo completo:
[INSERTE AQUÍ UN SOLO ANÁLISIS DEL PLAN]

Necesito que:

1. Lo hagas paso a paso con código, explicando cada decisión
2. Muestrés métricas, patrones y la visualización
3. Interpretes los hallazgos en el contexto del producto
4. Distingas asociación de causa
5. Identifiques limitaciones y sugieras un seguimiento

Incluye el código, para que yo pueda repetirlo.




TEXTO COMPLETO

El corchete es deliberado. Se ejecuta un análisis del plan, se valida, y solo entonces el siguiente. Eso es la etapa 04.



EL ALCOHOL SEPARA EN AMBOS; LO DEMÁS DEPENDE DEL TIPO



LA GRÁFICA QUE GENERÓ, SIN RETOCAR · 0,5 = NO SEPARA

En tintos

Los mejor calificados tienen menos acidez volátil y más sulfatos. En blancos, ninguna de las dos separa.

Lo que advirtió

«Estos resultados muestran asociación [...]. No muestran que cambiar una variable cambie la calificación.»

PUEDE USARLA PARA EL ANÁLISIS. DEBE DECLARARLO

Un análisis que usted no puede explicar no es suyo.

En cada entrega va qué herramienta usó, para qué, y cómo verificó el resultado. Nivel 3 significa que la IA edita y ejecuta; la decisión y la validación son suyas.

Herramienta	Para qué	Cómo lo verifiqué
Claude	Diagnóstico del CSV de vinos	Recalculé duplicados y faltantes con pandas
Claude	Comparación por tipo (AUC)	Repetí el Mann-Whitney con scipy

DÓNDE VA En la sección 07 del formato de la entrega final. La de hoy, la Entrega 1, también la lleva.



LA ÚNICA FORMA DE APRENDER ES CACHARREANDO

Descargue el archivo, corra los tres prompts y traiga a la próxima sesión una cosa que el modelo le haya dicho y que usted haya tenido que corregir.

